

Exercícios - Capítulo 01

Página 6

```
library(tidyverse)
```

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.1.4      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v ggplot2     4.0.1      v tibble     3.3.1
v lubridate  1.9.4      v tidyr      1.3.1
v purrr       1.2.0
```

```
-- Conflicts ----- tidyverse_conflicts() --
```


```
x dplyr::filter() masks stats::filter()
```

```
x dplyr::lag()     masks stats::lag()
```

```
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

1. Execute `ggplot(data = mpg)`. O que você vê?

```
ggplot(data = mpg)
```



2. Quantas linhas existem em `mtcars`? e quantas colunas?

```
nrow(mtcars)
```

```
[1] 32
```

```
ncol(mtcars)
```


```
[1] 11
```

3. O que a variável `drv` faz?

```
?mpg
```

4. Faça um gráfico de dispersão de `hwy` versus `cyl`


```
ggplot(mpg, aes(x = hwy, y=cyl))+  
  geom_point()
```



Página 12


1. O que há de errado com este código? Por que os pontos não estão pretos?

```
ggplot(data = mpg) +  
  geom_point(mapping = aes(x = displ, y = hwy, color = "blue"))
```



Resposta: Talvez porque o argumento `color` está dentro da função `aes()`. Ele meio que está atribuindo `color` à uma “variável” chamada “blue”. Exemplo de código com `color` fora da função:

```
ggplot(data = mpg) +  
  geom_point(mapping = aes(x = displ, y = hwy), color = "blue")
```



- Quais variáveis em `mpg` são categóricas? Quais variáveis são contínuas? Como você pode ver essa informação quando executa `mpg`?

```
?mpg
```

```
mpg
```

```
# A tibble: 234 x 11
```


	manufacturer	model	displ	year	cyl	trans	drv	cty	hwy	fl	class
	<chr>	<chr>	<dbl>	<int>	<int>	<chr>	<chr>	<int>	<int>	<chr>	<chr>
1	audi	a4	1.8	1999	4	auto~	f	18	29	p	comp~
2	audi	a4	1.8	1999	4	manu~	f	21	29	p	comp~
3	audi	a4	2	2008	4	manu~	f	20	31	p	comp~
4	audi	a4	2	2008	4	auto~	f	21	30	p	comp~
5	audi	a4	2.8	1999	6	auto~	f	16	26	p	comp~
6	audi	a4	2.8	1999	6	manu~	f	18	26	p	comp~
7	audi	a4	3.1	2008	6	auto~	f	18	27	p	comp~
8	audi	a4 quattro	1.8	1999	4	manu~	4	18	26	p	comp~
9	audi	a4 quattro	1.8	1999	4	auto~	4	16	25	p	comp~
10	audi	a4 quattro	2	2008	4	manu~	4	20	28	p	comp~

```
# i 224 more rows
```


Resposta: Consigo ver pelo cabeçalho das variáveis: onde está escrito `<int>` é porque são números inteiros, logo discretos, quando está escrito `<double>` é porque são números com casas decimais, logo contínuos.

3. Mapeie uma variável contínua para `color`, `size` e `shape`. Como essas estéticas se comportam de maneira diferente para variáveis categóricas e contínuas?

```
ggplot(data = mpg)+  
  geom_point(mapping = aes(x = displ, y = hwy, colour = displ))
```



```
ggplot(data = mpg)+  
  geom_point(mapping = aes(x = displ, y = hwy, size = displ))
```




```
ggplot(data = mpg)+
  geom_point(mapping = aes(x = displ, y = hwy, shape = displ))
```

Error in `geom\_point()`:
 ! Problem while computing aesthetics.
 i Error occurred in the 1st layer.
 Caused by error in `scale\_f()`:
 ! A continuous variable cannot be mapped to the shape aesthetic.
 i Choose a different aesthetic or use `scale\_shape\_binned()`.

Resposta: Para `colore size`, o código roda, mas ainda assim fica muito difícil de distinguir valores dessa forma. Para o argumento `shape` o código não roda, acho que principalmete pelo número limitado de formas.

4. O que acontece se você mapear a mesma variável a várias estéticas?


```
ggplot(data = mpg)+
  geom_point(mapping = aes(x = displ, y = displ, color = displ))
```



Resposta: Ele vai mapear normalmentr, só não é muito informativo.

5. O que a estética **stroke** faz? Com que formas ela trabalha?


```
?geom_point
ggplot(data = mpg)+
  geom_point(mapping = aes(x = displ, y = hwy), shape = 21, color = "blue", fill = "red", stroke = "red", size = 100)
```



Resposta: Altera a grossura da borda dos pontos.

6. O que acontece se você mapear uma estética a algo diferente de um nome de variável, como `aes(color = displ < 5)`

```
ggplot(data = mpg) +  
  geom_point(mapping = aes(x = displ, y = displ < 5, colour = displ < 5))
```




Resposta: Ele vai criar uma variável que assume **TRUE** se o valor da variável **displ** for menor que 5 e **FALSE** c.c.

Página 15

1. O que acontece se você criar facetas em uma variável contínua?


```
ggplot(data = mpg)+
  geom_point(mapping = aes(x = displ, y = hwy))+
  facet_wrap(~ displ, nrow = 2)
```




Resposta: Ele cria muitas facetas e fica difícil visualizar.

2. O que significam células em branco em um gráfico com `facet_grid(drv ~ cyl)`? Como elas funcionam a este gráfico?

```
ggplot(data = mpg)+
  geom_point(mapping = aes(x = drv, y = cyl))
```




```
ggplot(data = mpg)+
  geom_point(mapping = aes(x = displ, y = hwy))+
  facet_grid(drv ~ cyl)
```



Resposta: Algumas facetas ficarão em branco pois não existem dados com essas combinações de valores das duas variáveis. Assim com no primeiro gráfico há valores que não possuem observações.

3. Que gráficos o código a seguir faz?


```
ggplot(data = mpg)+  
  geom_point(mapping = aes(x = displ, y = hwy))+  
  facet_grid(drv ~ .)
```



Resposta: Ele faz um gráfico onde não há colunas mas apenas linhas. Ao contrário do `facet_grid(. ~ drv)`, que só possui colunas e não linhas.

4. Pegue o primeiro gráfico em facetas desta seção:

```
ggplot(data = mpg)+  
  geom_point(mapping = aes(x = displ, y = hwy))+  
  facet_wrap(~ class, nrow = 2)
```




Quais são as vantagens de usar facetas, em vez de estética de cor? Quais são as desvantagens? Como o equilíbrio poderia mudar se tivesse um conjunto de dados maior?

Resposta: A vantagem é que pode-se ver cada classe separadamente, sem que uma se sobreponha à outra. A desvantagem é que é um pouco mais demorado para se compreender algumas coisas nesse formato, pois se estivessem em um só gráfico com cores diferentes poderia ser mais rápida a compreensão. Quando há muitos valores diferentes de uma variável, fica quase impossível ter algum insight em cima desses gráficos, pois impossibilita a visualização de todos ao mesmo tempo.

5. Leia `?facet_wrap`. O que o `nrow` faz? O que o `ncol` faz? Quais outras opções controlam o layout de painéis individuais? Por que `facet_grid` não tem variáveis `ncol` e `nrow`?


Resposta: `nrow` é o número de linhas que as facetas vão ter e `ncol` o número de colunas. Exemplo: se eu tiver 3 facetas e digitar `nrow = 3`, cada linha vai ficar com uma faceta.

```
ggplot(data = mpg)+
  geom_point(mapping = aes(x = displ, y = hwy))+
  facet_wrap(~ class, nrow = 4, ncol = 2)
```




Outras opções são o argumento `space` que organiza as facetas conforme o eixo x ou y.

```
ggplot(data = mpg)+
  geom_point(mapping = aes(x = displ, y = hwy))+
  facet_wrap(~ class, space = "free_x")
```




```
ggplot(data = mpg)+
  geom_point(mapping = aes(x = displ, y = hwy))+
  facet_wrap(~ class, space = "free_y")
```




O `as.table` que altera o layout colocando as facetas originais ao contrário (de baixo para cima).


```
ggplot(data = mpg)+  
  geom_point(mapping = aes(x = displ, y = hwy))+  
  facet_wrap(~ class, as.table = TRUE)
```



```
ggplot(data = mpg)+  
  geom_point(mapping = aes(x = displ, y = hwy))+  
  facet_wrap(~ class, as.table = FALSE)
```




```
ggplot(data = mpg)+
  geom_point(mapping = aes(x = displ, y = hwy))+
  facet_grid(~class)
```




O `facet_grid` não possui os argumentos `nrow` e `ncol` porque como são combinações de valores de variáveis, o número de linhas e colunas já é pré-definido.

6. Ao usar `facet_grid()` você normalmente deveria colocar a variável com níveis mais singulares nas colunas. Por que?

```
ggplot(data = mpg)+  
  geom_point(mapping = aes(x = displ, y = hwy))+  
  facet_grid(drv ~ fl)
```



```
ggplot(data = mpg)+  
  geom_point(mapping = aes(x = displ, y = hwy))+  
  facet_grid(fl ~ drv)
```




Resposta: Porque se colocarmos nas linhas as variáveis com múltiplos níveis, os gráficos vão encolhendo muito ficando mais difícil de visualizar.

Página 20


1. Que geom você usaria para desenhar um gráfico de linha? Um diagrama de caixa (boxplot)? Um histograma? Um gráfico de área?

Resposta:

```
ggplot(data = mpg, mapping = aes(x = displ)) +
  geom_boxplot(fill = "#A599B5", color = "#00B9AE")
```




```
ggplot(data = mpg, mapping = aes(x = displ, y = hwy))+  
  geom_line(color = "#A599B5")
```




```
ggplot(data = mpg, mapping = aes(x = displ))+
  geom_histogram(fill = "#A599B5", color = "#00B9AE")
```

`stat\_bin()` using `bins = 30`. Pick better value `binwidth`.



```
ggplot(data = mpg, mapping = aes(x = year, y = cyl))+
  geom_area(fill = "#00B9AE")
```




2. Execute este código em sua cabeça e preveja como será o resultado. Depois execute o código em R e confira suas previsões.

```
ggplot(
  data = mpg,
  mapping = aes(x = displ, y = hwy, color = drv)
)+
  geom_point()+
  geom_smooth(se = FALSE)
```

Resposta: Ele criará um gráfico de dispersão entre `displ` e `hwy` com as cores sendo os diferentes valores da variável `drv`. Depois criará uma linha sem a sombra na borda dela, também com cores diferentes conforme a variável `drv`.

```
ggplot(
  data = mpg,
  mapping = aes(x = displ, y = hwy, color = drv)
)+
  geom_point()+
  geom_smooth(se = FALSE)
```

```
`geom_smooth()` using method = 'loess' and formula = 'y ~ x'
```



3. O que `show_legend = FALSE` faz? O que acontece se você removê-lo? Por que você acha que usei isso anteriormente no capítulo?

Resposta: Ele esconde a legenda de cores/formas/tamanhos do `mapping`. Caso removido ele mostra a legenda com cores. Acho que usei para mostrar que quando há cores envolvidas o `ggplot` automaticamente mostra a legenda, o que não acontece em outros gráficos sem cores como `aes`.

4. O que o argumento `separa geom_smooth()` faz? **Resposta:** Esconde aquela sombra que fica em torno da linha.
5. Esses gráficos serão diferentes? Por que/por que não?


```
ggplot(data = mpg, mapping = aes(x = displ, y = hwy))+
  geom_point()+
  geom_smooth()
```

```
ggplot()+
  geom_point(data = mpg, mapping = aes(x = displ, y = hwy))+
  geom_smooth(data = mpg, mapping = aes(x = displ, y = hwy))
```

Resposta: Não serão diferentes pois o que muda é só a sintaxe.


```
ggplot(data = mpg, mapping = aes(x = displ, y = hwy))+
  geom_point()+
  geom_smooth()
```

`geom\_smooth()` using method = 'loess' and formula = 'y ~ x'



```
ggplot()+
  geom_point(data = mpg, mapping = aes(x = displ, y = hwy))+
  geom_smooth(data = mpg, mapping = aes(x = displ, y = hwy))
```


`geom\_smooth()` using method = 'loess' and formula = 'y ~ x'



6. Recrie o código R necessário para gerar os seguintes gráficos:


```
ggplot(data = mpg, mapping = aes(x = displ, y = hwy))+  
  geom_point()+  
  geom_smooth(se = FALSE)
```

`geom\_smooth()` using method = 'loess' and formula = 'y ~ x'




```
ggplot(data = mpg, mapping = aes(x = displ, y = hwy))+  
  geom_point()+  
  geom_smooth(aes(group = drv), se = FALSE)
```

`geom\_smooth()` using method = 'loess' and formula = 'y ~ x'




```
ggplot(data = mpg, mapping = aes(x = displ, y = hwy))+  
  geom_point(aes(color = drv))+  
  geom_smooth(aes(color = drv), se = FALSE)
```

`geom\_smooth()` using method = 'loess' and formula = 'y ~ x'




```
ggplot(data = mpg, mapping = aes(x = displ, y = hwy))+  
  geom_point(aes(color = drv))+  
  geom_smooth(se = FALSE)
```

``geom_smooth()`` using method = 'loess' and formula = 'y ~ x'




```
ggplot(data = mpg, mapping = aes(x = displ, y = hwy))+  
  geom_point(mapping = aes(color = drv))+  
  geom_smooth(mapping = aes(linetype = drv), se = FALSE)
```

`geom\_smooth()` using method = 'loess' and formula = 'y ~ x'



```
ggplot(data = mpg, mapping = aes(x = displ, y = hwy, fill = drv))+
  geom_point(shape = 21, color = "white", size = 3,stroke = 2 )
```




Página 26

1. Qual é o geom padrão associado a `stat_summary`? Como você poderia reescrever o gráfico anterior usando a função `geom`, em vez da função `stat`?

Resposta: O `geom_pointrange`.


?stat_summary

```
ggplot(data = diamonds)+  
  geom_pointrange(  
    mapping = aes(x = cut, y = depth),  
    stat = "summary",  
    fun.min = min,  
    fun.max = max,  
    fun = median)
```




2. O que `geom_col()` faz? Qual a diferença entre ele e `geom_bar()`? **Resposta:** O `geom_bar` usa a frequência daquele nível na variável y e o `geom_col` utiliza alguma variável dentro do conjunto de dados como y. Em resumo, o `geom_col` é um `geom_bar` com argumento `stat = "identity"`.

```
ggplot(data = diamonds)+  
  geom_bar(mapping = aes(x = cut))
```



```
dados <- diamonds %>% count(cut)  
ggplot(data = dados)+  
  geom_col(mapping = aes(x = cut, y = n))
```



3. A maioria dos geoms e stats vem em pares, que são quase sempre usados juntos. Leia a documentação e faça uma lista de todos os pares. O que eles têm em comum?

Resposta:

Stat	Geom
stat_align	geom_area
stat_bin	geom_bar
stat_bin_2d	geom_tile
stat_bin_hex	geom_hex
stat_bin2d	geom_tile
stat_binhex	geom_hex
stat_boxplot	geom_boxplot
stat_connect	geom_path
stat_contour	geom_contour
stat_contour_filled	geom_contour_filled
stat_count	geom_bar
stat_density	geom_area
stat_density_2d	geom_density2d
stat_density2d_filled	geom_density2d_filled
stat_ecdf	geom_step
stat_ellipse	geom_path
stat_function	geom_function

Stat	Geom
stat_identity	geom_point, geom_spoke
stat_manual	geom_point
stat_qq	geom_point
stat_qq_line	geom_abline
stat_quantile	geom_quantile
stat_sf	geom_rect
stat_sf_coordinates	geom_point
stat_smooth	geom_smooth
stat_sum	geom_point
stat_summary	geom_pointrange
stat_summary_2d	geom_tile
stat_summary_bin	geom_pointrange
stat_summary_hex	geom_hex
stat_summary2d	geom_tile
stat_unique	geom_point
stat_ydensity	geom_violin
stat_smooth	geom_smooth
stat_smooth	geom_smooth

Ambos apresentam a mesa camada do gráfico.

4. Quais variáveis `stat_smooth` calcula? Quais parâmetros controlam seu comportamento?

Resposta:


`ymin` = o limite inferior do intervalo de confiança para o valor predito. `ymax` = o limite superior do intervalo de confiança do valor predito. `se` = o erro padrão.

`method` = controla qual algoritmo será usado para calcular a curva. `formula` = controla a equação do modelo. `se` = controla se o gráfico irá mostrar o erro padrão ou não. `fullrange` = se `TRUE` calculará a linha para além dos dados coletados.


5. Em nosso gráfico de barras de `proportion`, precisamos configurar `group = 1`. Por quê? Em outras palavras, qual é o problema com esses dois gráficos.

```
ggplot(data = diamonds)+
  geom_bar(mapping = aes(x = cut, y = ..prop..))
```

Warning: The dot-dot notation (`..prop..`) was deprecated in ggplot2 3.4.0.
i Please use ``after_stat(prop)`` instead.



```
ggplot(data = diamonds)+  
  geom_bar(mapping = aes(x = cut, fill = color, y = ..prop..))
```




Resposta: O problema é que ele vai colocar todos os níveis com proporção 1 e todos os níveis do gráfico 2 terão todas as cores da variável color.

Página 31


1. Qual é o problema com este gráfico? Como você poderia melhorá-lo?

```
ggplot(data = mpg, mapping = aes(x = cty, y = hwy)) +  
  geom_point()
```




Resposta: Como é uma variável discreta, está ocorrendo o *overpotting*. A melhoria está na utilização do argumento `position = jitter`.

```
ggplot(data = mpg, mapping = aes(x = cty, y = hwy)) +  
  geom_point(position = position_jitter())
```




2. Quais parâmetros para `geom_jitter()` controlam a quantidade de oscilação? **Resposta:** Os parâmetros `width` e `height`.
3. Compare e contraste `geom_jitter()` com `geom_count()`.

```
ggplot(data = mpg)+  
  geom_jitter(mapping = aes(x = displ, y = hwy))
```



```
ggplot(data = mpg)+
  geom_count(mapping = aes(x = displ, y = hwy))
```



Resposta: A diferença é que o `jitter` espalha mais os pontos, evitando que se sobreponham, já o `count` conta quantos pontos se sobrepõem e a quantidade. Depende muito do objetivo do gráfico.


4. Qual é o ajuste de posição padrão para `geom_boxplot()`? Crie uma visualização do conjunto de dados `mpg` que demonstre isso.

Resposta: `dodge2`. Ele evita que vários boxplots fiquem sobrepostos.


```
library(ggplot2)
library(stringr)

mpg_modificado <- mpg |>
  mutate(
    tipo_transmissao = if_else(str_detect(trans, "auto"), "Automático", "Manual")
  )

ggplot(data = mpg_modificado) +
  geom_boxplot(
    mapping = aes(x = drv, y = hwy, fill = tipo_transmissao), position = "dodge2"
  )
```



```
ggplot(data = mpg_modificado) +
  geom_boxplot(
    mapping = aes(x = drv, y = hwy, fill = tipo_transmissao), position = "identity"
  )
```




Página 33

1. Transforme um gráfico de barras empilhadas em um gráfico de pizza usando `coord_polar()`.

Resposta:


```
ggplot(data = diamonds)+
  geom_bar(mapping = aes(x = cut, fill = clarity))+
  coord_polar()
```




2. O que `labs()` faz? Leia a documentação. **Resposta:** Adiciona título, subtítulo, legendas aos eixos e legenda ao gráfico.
3. Qual é a diferença entre `coord_quickmap()` e `coord_map()`?

```
nz <- map_data("nz")

ggplot(nz, aes(long, lat, group = group))+
  geom_polygon(fill = "white", color = "black")+
  coord_quickmap()
```




```
ggplot(nz, aes(long, lat, group = group))+  
  geom_polygon(fill = "white", color = "black")+  
  coord_map()
```



Resposta: Olhando assim, parece que não há diferença. Mas na documentação está escrito que `coord_map()` corrige as curvas e linhas e `coord_quickmap()` é uma aproximação rápida que preserva as linhas retas mas ignora a curvatura da terra. `coord_map()` é melhor para projetar áreas grandes do mundo inteiro, já `coord_map()` trabalha melhor com áreas menores próximas à linha do equador, onde a distorção é mínima.

4. O que o gráfico a seguir lhe diz sobre a relação entre `mpg` de cidade e estrada? Por que `coord_fixed()` é importante? O que `geom_abline()` faz?

```
ggplot(data = mpg, mapping = aes(x = cty, y = hwy)) +  
  geom_point() +  
  geom_abline() +  
  coord_fixed()
```



Resposta: Que na cidade geralmente se gasta mais combustível do que na estrada. O `coord_fixed()` é importante porque força uma proporção específica entre a representação de unidades dos dados nos eixos. A proporção representa o número de unidades de y equivalente a uma unidade de x. Já o `geom_abline()` traça uma linha onde $x = y$ para entender melhor se $y > x$, ou $y < x$. No caso desse gráfico, $y > x$.